
TIAGO DA SILVA
JOÃO ALCINDO RIBEIRO DE AZEVEDO
GERMANO ANDRADE BRANDÃO

RELATÓRIO
COMPUTAÇÃO ESCALÁVEL

RIO DE JANEIRO
2022

Sumário

1	Introdução	3
2	Pipeline	3
2.1	Extração	5
2.2	Transformação	5
2.3	Carregamento	5
3	Armazenamento em nuvem (AWS)	5
3.1	AmazonMQ	5
3.2	RDS	6
3.3	ECR	6
3.4	ECS	6
4	Interface com o usuário	6

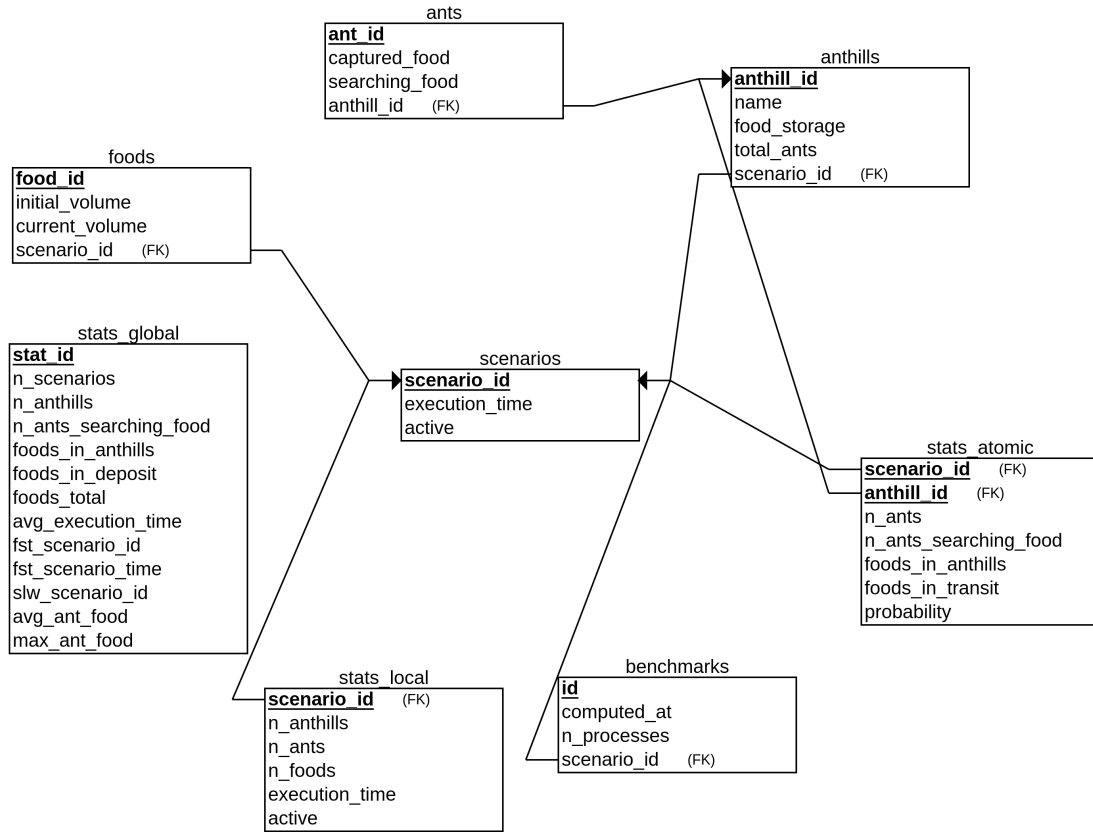


Figura 1: Modelo relacional do banco de dados utilizado para a captura persistente dos dados gerados pela simulação.

1 Introdução

Trataremos aqui das decisões de projetos adotadas ao longo do trabalho, procurando esclarecer o nosso ponto de vista acerca de cada escolha. Além disso, toda a estrutura será detalhada, de forma a ser possível entender bem como funciona todo o processo de simulação de ponta a ponta. Por fim, mostraremos como o trabalho foi adaptado para que fosse processado em nuvem, utilizando majoritariamente os serviços da Amazon AWS.

2 Pipeline

Escolhemos uma pipeline de extração, transformação e carregamento (ETL, em oposição a ELT); importante, esta escolha está amarrada à contemplação de que os procedimentos para serializar os dados e os tornar receptivos a um banco

de dados relacional gozam de intensidade computacional enxuta. Utilizamos, para isso, um banco de dados alicerçado no modelo relacional da Figura 1. Nas seções seguintes, desta maneira, descrevemos a implementação de cada estágio de nosso pipeline ETL.

Neste íterim, advogamos o modelo escolhido e apresentamos o framework geral para controlar a comunicação entre os processos responsáveis pela inserção dos dados em um banco de dados. Inicialmente, as tabelas `scenarios`, `ants`, `anthills` e `foods` almejam incorporar as informações brutas geradas pelas simulações; isso enseja a expansão da amplitude de análises subsequentes. As tabelas com prefixo `stats_`, por outro lado, são atualizadas periodicamente e permitem, desta maneira, o acesso, em diferentes aspectos de granularidades¹, às informações por usuários (na Seção 4, exploramos o desenho de uma interface que direciona o usuário ao exame dos cenários correntes e passados). Alternativamente, poderíamos

1. implementar uma base de dados analítica, com um modelo dimensional que combinasse parcimoniosamente as tabelas para o cômputo das quantidades solicitadas nos requisitos da modelagem;
2. e, mais disruptivamente, optar pela utilização de um banco de dados noSQL, com um pipeline ELT, em que os dados seriam armazenados e, em seguida, processados.

Nestas condições, nossas escolhas estão amarradas a compleições objetivas: com respeito a 1, precisaríamos comportar, em nosso sistema, um mecanismo de transferência de informações entre um banco de dados operacional e um analítico, transcendendo, em nossa opinião, o objetivo desta avaliação, que não inclui a modelagem dimensional; com respeito a 2, nossas breves exposições a bancos de dados noSQL (como o MongoDB) culminaram em nossas reticências em os introduzir neste sistema. Neste cenário, nossas escolhas por um banco de dados relacional estão alicerçadas em sua conveniência e na existência de múltiplas ferramentas que permitem a sua integração em um sistema distribuído.

¹Explicitamente, escrevemos `global` para as análises globais, que tangenciam todos os cenários executados; `local`, para as análises que consolidam os aspectos de cada cenário; e `atomic`, para as análises que conformam as instâncias que apontam para os formigueiros.

2.1 Extração

2.2 Transformação

2.3 Carregamento

3 Armazenamento em nuvem (AWS)

O processamento e o armazenamento locais podem ser vantajosos por ter uma velocidade alta e não depender de conexões externas. No entanto, essas vantagens podem acabar rapidamente ao passo que a quantidade a ser processada/armazenada começa a aumentar. Nesse sentido, uma das alternativas mais adotadas atualmente é a de computação em nuvem, onde um ambiente vasto com soluções prontas ou customizáveis são disponibilizadas e de forma escalável, de acordo com a demanda.

Dito isso, para esse trabalho utilizamos alguns dos serviços de nuvem da Amazon Web Services, a fim de agregar mais robustez ao nosso pipeline de dados. Assim, veremos agora quais recursos foram utilizados e informações das instâncias criadas em cada um deles.

3.1 AmazonMQ

Uma vez que utilizamos o RabbitMQ como broker, temos o AmazonMQ como serviço de gerenciamento de mensagens na AWS para criar uma instância com o RabbitMQ.

Ao instanciar com as opções devidamente escolhidas, ficamos com as seguintes informações

Broker engine	Engine version	Instance type
RabbitMQ	3.9.16	mq.t3.micro

Tabela 1: Informações da instância na AmazonMQ

A partir disso, podemos nos conectar com o broker a partir dos dados a seguir.

ARN (Amazon Resource Name)	RabbitMQ web console	port
arn:aws:mq:us-east-1:676432491375:broker:TJG:b-7182fca9-4c07-4bfa-be01-72310cb18d60	https://b-7182fca9-4c07-4bfa-be01-72310cb18d60.mq.us-east-1.amazonaws.com	5671

Tabela 2: Informações para conexão

Para acessar o console, basta utilizar as credenciais a seguir.

Username	Password
username	passwordpassword

Tabela 3: Credenciais RabbitMQ

3.2 RDS

3.3 ECR

Para hospedar imagens Docker, utilizamos o Amazon ECR (*Elastic Container Registry*) que é um registro de contêiner totalmente gerenciado da Amazon AWS.

Nesse sentido, criamos dois repositórios, um para o *celery* e outro para o *spark*.

Repository name	URI
tjg-celery	676432491375.dkr.ecr.us-east-1.amazonaws.com/tjg-celery
tjg-spark	676432491375.dkr.ecr.us-east-1.amazonaws.com/tjg-spark

Tabela 4: Informações das imagens

3.4 ECS

Para gerenciar os containers, utilizamos o Amazon ECS (*Elastic Container Service*), onde podemos executar tarefas dentro do cluster.

Cluster	Cluster ARN	Launch type
TJG	arn:aws:ecs:us-east-1:676432491375:cluster/TJG	FARGATE ²

Tabela 5: Informações do cluster

Com isso, ficamos aptos a definir as *tasks*

4 Interface com o usuário

²O [AWS Fargate](#) é uma tecnologia que pode ser usada com o Amazon ECS para executar contêineres sem a necessidade de gerenciar servidores ou clusters de instâncias do Amazon EC2.